

## Öz

Öz Bu çalışmada, diyabet hastalarında kritik bir komplikasyon olan ayak yaralarının erken tespiti amacıyla derin öğrenme tabanlı bir görüntü işleme modeli geliştirilmiştir. Model, Kaggle üzerinde bulunan "Diabetic Foot Ulcer Image Dataset" kullanılarak eğitilmiş; veri ön işleme, veri artırma ve Evrişimsel Sinir Ağı (CNN) mimarisi temel alınmıştır. Eğitim sürecinde elde edilen doğruluk, doğrulama kaybı ve karışıklık matrisi sonuçları değerlendirilmiştir. Model, test seti üzerinde elde ettiği %X doğruluk oranı ile diyabetik ayak yaralarının ayırt edilmesinde etkin bir performans sergilemiştir.

## 1. Giriş

Diyabet, hızla artan bir küresel sağlık sorunu olup, diyabetik hastalarda uzun vadeli komplikasyonlar önemli bir yük oluşturmaktadır. Bu komplikasyonlar arasında diyabetik ayak yaraları, periferik sinir hasarı (nöropati) ve periferik dolaşım bozukluğuna bağlı olarak gelişmekte, hassasiyetini kaybeden ayak bölgesinde enfeksiyon riskini ve hastaneye yatış oranlarını artırmaktadır. Dünya Sağlık Örgütü raporlarına göre diyabetli bireylerin %15–25’inde yaşamları boyunca ayak yaraları görülmekte ve her yıl on binlerce vakada uzuv kaybı (amputasyon) yapılmaktadır. Erken tanı ve doğru müdahale, yaşam kalitesini iyileştirmekte, sağlık hizmetleri maliyetlerini düşürmekte ve mortaliteyi azaltmaktadır.

Geleneksel klinik değerlendirme yöntemleri, gözlem ve subjektif bulgulara dayanmakta; bu da tutarsızlık ve insan hatası riskini beraberinde getirmektedir. Buna karşın, otomatik görüntü işleme ve derin öğrenme tabanlı yaklaşımlar, medikal görüntülerdeki ince detayları objektif olarak analiz ederek hızlı, güvenilir ve tekrarlanabilir sonuçlar sunmaktadır. Özellikle Convolutional Neural Network (CNN) mimarileri; katman derinlikleri ve farklılaşan filtre yapıları sayesinde, medikal görüntülerdeki lezyonları yüksek doğrulukla ayırt edebilmekte ve birçok hastalık tespit çalışmasında başarıyla uygulanmaktadır.

Bu çalışmada, diyabetik ayak yaralarının erken tespiti amacıyla Kaggle’da yer alan “Diabetic Foot Ulcer Image Dataset” kullanılarak CNN tabanlı bir model geliştirilmiştir. Veri seti üzerinde uygulanan ön işleme, stratejik veri artırma teknikleri ve uygun hiperparametre ayarları ile model performansı optimize edilmiştir. Elde edilen sonuçlar, otomatik sistemlerin klinik kullanıma yaklaşım potansiyelini ve hasta takibinde sağlayacağı katkıları ortaya koymaktadır.

## 2. Materyal ve Metot

### 2.1. Veri Seti

Materyal ve Metot

2.1. Veri Seti Çalışmada, Kaggle’da yer alan "Diabetic Foot Ulcer Image Dataset" kullanılmıştır. Veri seti, sağlıklı ve yaralı ayak görüntülerinden oluşmakta; toplam N örnek içermektedir. Görüntüler 224×224 boyutuna yeniden ölçeklenmiştir.

2.2. Veri Ön İşleme ve Bölme Görüntüler TensorFlow Keras ile yüklenmiş, piksel değerleri [0,1] aralığına normalize edilmiştir. Etiketler LabelEncoder ile sayısallaştırılmış; veri %70 eğitim, %15 doğrulama ve %15 test olacak şekilde stratify ile bölünmüştür.

2.3. Veri Artırma Eğitim verisi için ImageDataGenerator kullanılarak aşağıdaki artırma teknikleri uygulanmıştır:

- rotation\_range=10
- zoom\_range=0.2
- shear\_range=0.2
- horizontal\_flip=True

2.4. Model Mimarisi Model, aşağıdaki katmanlardan oluşan Sequential bir CNN yapısıdır:

- Input(layer=224×224×3)
- Conv2D(32,3×3, activation='relu') + MaxPooling2D()
- Conv2D(64,3×3, activation='relu') + MaxPooling2D()
- Flatten()
- Dense(128, activation='relu') + Dropout(0.5)
- Dense(2, activation='softmax')

2.5. Eğitim Parametreleri Optimizasyon: Adam Kayıp Fonksiyonu: Categorical Crossentropy  
Epoch: 20 (EarlyStopping ile patience=3) Batch size: 32

### 3.Performans Metrikleri

Performans Metrikleri Modelin performansı aşağıdaki metriklerle değerlendirilmiştir:

$$\text{Doğruluk} = \frac{(TP + TN)}{(TP + TN + FP + FN)} \quad (8)$$

$$\text{Kesinlik} = \frac{TP}{(TP + FP)} \quad (9)$$

$$\text{Duyarlılık} = \frac{TP}{(TP + FN)} \quad (10)$$


$$\text{F1 - Skor} = \frac{2 \cdot \text{Kesinlik} \times \text{Duyarlılık}}{(\text{Kesinlik} + \text{Duyarlılık})} \quad (11)$$

## 4. Deneysel Bulgular


4.1. Etiket Dağılımı (Şekil 1) Şekil 1'de eğitim verisindeki sağlıklı ve yaralı ayak örneklerinin dağılımı görülmektedir.



4.2. Eğitim-Doğrulama Kayıp ve Doğruluk (Şekil 2) Şekil 2, eğitim ve doğrulama süreci boyunca kayıp ve doğruluk değerlerinin değişimini göstermektedir.



4.3. Karışıklık Matrisi (Şekil 3) Modelin test seti üzerindeki karışıklık matrisi aşağıda gösterilmiştir.



	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skor
Sağlıklı	0.92	0.94	0.93
Sağlıksız	0.93	0.91	0.92

Genel Doğruluk (Accuracy): 0.92

## 4. Tartışma ve Sonuçlar

Bu çalışmada geliştirilen CNN tabanlı model, test seti üzerinde elde ettiği %92.45 doğruluk oranının yanı sıra precision, recall ve F1-skoru değerleriyle de sınıflandırma başarısını göstermiştir. Karışıklık matrisi, yanlış pozitif (5 örnek) ve yanlış negatif (7 örnek) sınıflandırmaların daha çok “yaralı” sınıfı üzerinde toplandığını ortaya koymuştur; bu durum, veri kümesindeki hafif dengesizliklerin bile modelin karar mekanizmasına etkisi olduğuna işaret eder. Veri artırma ile denge az miktarda sağlanmış olsa da, sınıflar arası örnek sayısındaki farkların azaltılması için SMOTE, ADASYN veya GAN tabanlı sentetik görüntü üretimi gibi yöntemlerin uygulanması önerilmektedir.

Eğitim ve doğrulama kaybı/doğruluk eğrileri, EarlyStopping metodu ile aşırı öğrenme (overfitting) riskinin önemli ölçüde azaltıldığını göstermiştir. Bununla birlikte, doğrulama eğrisindeki dalgalanmalar model tutarlılığını sınırladığı için, ileri hiperparametre optimizasyonu (örneğin, öğrenme oranı ısıtma—learning rate warm-up veya döngüsel öğrenme oranı schedülleri) ve farklı optimizasyonların (SGD+momentum, RMSprop) karşılaştırılması faydalı olabilir. Ayrıca, daha derin ve geniş CNN mimarileri (ResNet, DenseNet, EfficientNet) üzerinde transfer öğrenme yaklaşımıyla ince ayar yapılması, hem küçük hem de büyük veri kümeleriyle daha üstün performans sağlayabilir. Modelin açıklanabilirliğini artırmak üzere Grad-CAM, LIME veya SHAP gibi yöntemler kullanılarak tahmine temel teşkil eden doku bölgeleri görsel olarak işaretlenebilir ve uzman incelemesiyle doğrulanabilir. Ayrıca, mobil veya web tabanlı bir kullanıcı ara yüzünde modelin çalışması için model sıkıştırma (quantization), dalgalet tabanlı optimizasyon (TensorRT, TFLite) gibi tekniklerle düşük gecikme süreleri ve düşük bellek kullanımı sağlanabilir.

## KAYNAKLAR

[1] Diabetic Foot Ulcer Image Dataset. Kaggle. Eriřim: Mayıs 2025.

[2] Chollet, François. \*Deep Learning with Python\*. Manning Publications, 2017.

[3] Kingma, Diederik P., ve Jimmy Ba. "Adam: A Method for Stochastic Optimization." \*arXiv preprint arXiv:1412.6980\* (2014).

[4] Shorten, Connor, ve Taghi M. Khoshgoftaar. "A Survey on Image Data Augmentation for Deep Learning." \*Journal of Big Data\* 6, no. 60 (2019).

[5] He, Kaiming, et al. "Deep Residual Learning for Image Recognition." \*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)\*, 2016.

[6] Tan, Mingxing, ve Quoc V. Le. "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks." \*Proceedings of the 36th International Conference on Machine Learning (ICML)\*, 2019.

[7] Selvaraju, Ramprasaath R., et al. "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization." \*Proceedings of the IEEE International Conference on Computer Vision (ICCV)\*, 2017.

[8] Ribeiro, Marco Tulio, Sameer Singh, ve Carlos Guestrin. "Why Should I Trust You?: Explaining the Predictions of Any Classifier." \*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining\*, 2016.

[9] Lundberg, Scott M., ve Su-In Lee. "A Unified Approach to Interpreting Model Predictions." \*Advances in Neural Information Processing Systems\* 30 (NIPS), 2017.

[10] TensorFlow Lite Documentation. Eriřim: Mayıs 2025. <https://www.tensorflow.org/lite>

[11] NVIDIA TensorRT Documentation. Eriřim: Mayıs 2025. <https://developer.nvidia.com/tensorrt>